

PROCESAMIENTO DE LENGUAJE NATURAL • ITBA

Clasificación automática de noticias según patrones lingüísticos de las fake news

Modelos de NLP que separan noticias falsas de reales por su estilo lingüístico — con foco en la interpretabilidad: no qué modelo gana, sino qué rasgos del texto discriminan.

Baselines BoW/TF-IDF

Features lingüísticas

GloVe · Word2Vec

DistilBERT

Integrantes: [Nombre 1] · [Nombre 2] · [Nombre 3]

Dataset: Fake and Real News (Kaggle) · 44.898 artículos en inglés (2015–2018)

01

Objetivos y motivación

Qué problema resolvemos y por qué importa la interpretabilidad.

¿Qué queremos hacer y por qué?

- **Problema:** la desinformación se propaga más rápido que su verificación manual.
- **Objetivo:** entrenar y comparar clasificadores supervisados que separen noticias falsas de reales por sus patrones lingüísticos.
- **Importante:** los modelos detectan correlaciones de estilo en el corpus — NO verifican la veracidad factual.
- Énfasis en interpretabilidad: qué rasgos discriminan (longitud de oración, carga emocional, densidad de entidades, URLs), no solo qué modelo puntúa mejor.
- Herramienta de apoyo a la verificación humana, consciente de los sesgos del dataset.

HIPÓTESIS DE INVESTIGACIÓN

H₁ Las fake usan adjetivos con más carga emocional que el periodismo formal.

H₂ El cuerpo completo clasifica mejor que el titular solo.

H₃ El rendimiento cae al borrar marcadores de fuente (“reuters”).

02

Datos y metodología

El corpus, el análisis exploratorio y el diseño experimental.

El corpus: Fake and Real News (Kaggle)

44.898

artículos en inglés (True + Fake)


21.417

noticias reales · fuente: Reuters (2016-17)


23.481

noticias falsas (2015 - feb 2018)


- Columnas: title, text, subject, date. La columna subject NUNCA se usa como feature (es un sesgo del dataset).
- Clases balanceadas (~48% reales / 52% falsas) → facilita el entrenamiento supervisado.
- **Split TEMPORAL 70/15/15 (no aleatorio): se entrena con el pasado y se evalúa con artículos más recientes.**
- Tras parsear fechas y deduplicar (title, text): 44.898 → 39.099 registros para los splits.
- **Foco: subconjunto POLÍTICO (real=politicsNews, fake=politics) para controlar el sesgo temático; dataset completo solo como control.**



Longitud de textos y pipeline de limpieza



Las fake tienen mayor variabilidad y cola más larga (423 vs 386 palabras prom.)



PIPELINE DE PREPROCESAMIENTO

- Minúsculas; eliminación de números y caracteres especiales.
- Se conservan ! y ? (señales de estilo) y se reemplazan URLs por [URL].
- Tokenización; variantes con y sin stopwords (se mide el impacto).
- Sin lematización en baselines: se preservan formas superficiales discriminativas.
- Parseo de fechas multi-formato + deduplicación exacta antes de particionar (evita leakage).
- Se conserva el texto crudo para medir mayúsculas, exclamaciones y sentimiento (Exp 2).

Cómo lo hicimos: 5 experimentos, una métrica

MÉTRICA PRINCIPAL

F2-score (clase fake)

Prioriza recall: un falso negativo (fake pasada como real) es más costoso que un falso positivo.

- Etiquetas: fake = 1 (clase positiva), real = 0.
- Hiperparámetros elegidos SOLO en validación; test se evalúa una única vez.
- Split temporal → val/test pueden tener desbalance de clases (es esperado).

1

Baselines tradicionales

BoW/TF-IDF × LR/NB/SVM + ablación de fuente

2

Features lingüísticas

8 rasgos interpretables (spaCy + VADER) → LR

3

Embeddings & Transformers

GloVe · Word2Vec · DistilBERT (fine-tuning)

4

Importancia de atributos

Coefficientes lineales + adjetivos por clase

5

Análisis de errores

Taxonomía manual de FP/FN; baseline vs transformer

¿Por qué partición temporal y no aleatoria?

Como las noticias tienen fecha, ordenamos por fecha de publicación y cortamos en bloques: entrenamos con el pasado y evaluamos con artículos más recientes. Simula el escenario real de detección.



- **Validación:** ajuste de hiperparámetros y detección de overfitting.
- **Test:** se evalúa una sola vez, con la mejor configuración.
- Más realista que una partición aleatoria: el modelo no ve el futuro durante el entrenamiento.
- **Consecuencia:** val/test pueden quedar desbalanceadas en clases. Es esperado — no reordenamos para no romper el criterio temporal.
- También evita leakage: deduplicamos por (title, text) antes de particionar.

Métricas: precisión, recall y por qué F2

		Predicción	
		Real (0)	Fake (1)
Real	Real	VN	FP
	Fake	FN	VP

Convención: fake = 1 (clase positiva), real = 0.

Precisión

$$VP / (VP + FP)$$

De lo marcado como fake, ¿cuánto era fake?

Recall

$$VP / (VP + FN)$$

De las fake reales, ¿cuántas detectamos?

F2-score

$$(1+2^2) \cdot P \cdot R / (2^2 \cdot P + R)$$

Media F con $\beta=2$: el recall pesa 4× más que la precisión.

¿Por qué F2 y no F1/accuracy? Un falso negativo (una fake que pasa como real) es más dañino que un falso positivo. F2 prioriza no dejar pasar fakes.

03

Resultados

Cinco experimentos: de los baselines clásicos a los Transformers.

¿Cómo convertimos texto en números?

Los modelos no leen palabras: necesitan vectores. Las dos representaciones clásicas cuentan palabras, sin entender contexto ni orden.

B Bag of Words (BoW)

- Cuenta la frecuencia bruta de cada palabra en el documento.
- Simple e interpretable, pero da peso alto a palabras frecuentes aunque no discriminen.
- Vector disperso, sin semántica ni orden.

T TF-IDF

- **Pondera:** frecuencia en el documento $\times$ rareza en el corpus.
- Penaliza términos comunes (the, is) y resalta los discriminativos.
- Nuestra representación principal sobre BoW simple.

Bigramas: además de palabras sueltas (unigramas) probamos pares — “white house”, “breaking news” — que capturan expresiones con significado propio.

Los tres clasificadores clásicos

Sobre las representaciones BoW/TF-IDF entrenamos tres modelos supervisados estándar. Todos son rápidos e interpretables; sirven como línea de base.



Regresión Logística

- Modela la probabilidad de que una noticia sea fake.
- Frontera de decisión lineal sobre las palabras.
- **Hiperparámetro C: regula la fuerza de la regularización (sobreajuste vs. simplicidad).**
- Coeficientes interpretables por término.



Naive Bayes

- Modelo probabilístico (multinomial) sobre conteos de palabras.
- Asume independencia entre palabras: ingenuo pero efectivo en texto.
- **Hiperparámetro alpha: suavizado de Laplace para palabras no vistas.**
- Muy rápido de entrenar.



Linear SVM

- Busca el hiperplano de máximo margen entre clases.
- Robusto en espacios de alta dimensión (muchas palabras).
- **Hiperparámetro C: equilibra margen amplio vs. errores de clasificación.**
- **Fue nuestro mejor baseline.**

Baselines tradicionales (BoW / TF-IDF)


0,989

F2 fake (test) — LinearSVM + BoW(1,2)


0,998

ROC-AUC en test

- Mejor: LinearSVM, BoW, cuerpo, sin stopwords, bigramas.
- Solo 17 errores en test (6 FP, 11 FN).
- **F2≈0,99: el dataset se separa casi trivialmente.**




Matriz de confusión (test)



Curva ROC (test)

H3 — ¿El modelo se apoya en la fuente?



H3 NO confirmada

El modelo aprende patrones lingüísticos, no identidad de fuente.

- Normalizar “reuters/ap/afp” → [SOURCE] baja el F2 en validación solo ~0,020 (0,992 → 0,972).
- **Por debajo del umbral de 0,03 → no se activa la normalización de fuente.**
- Hallazgo positivo de validez: la señal aprendida es mayormente de estilo lingüístico.
- Matiz: el dataset sigue teniendo fuente única (Reuters) en la clase real → ver Limitaciones.

Las herramientas: spaCy y VADER

Para extraer los 8 rasgos de estilo combinamos dos librerías especializadas en lenguaje natural.



spaCy (en_core_web_sm)

- **POS tagging:** etiqueta cada palabra (adjetivo, sustantivo, pronombre...).
- **NER:** reconoce entidades nombradas (personas, lugares, organizaciones).
- Segmentación de oraciones (para longitud y densidad).
- Entrenado en OntoNotes (texto periodístico) → muy preciso en noticias.
- Usamos sm y no lg: POS/NER/segmentación son casi idénticos y evitamos ~560 MB de word vectors que no usamos.



VADER

- **Analizador de sentimiento basado en lexicón, diseñado para texto informal.**
- Maneja nativamente MAYÚSCULAS, signos de exclamación e hipérbole — justo los patrones sensacionalistas.
- Devuelve un score compuesto en [-1, +1] (muy negativo → muy positivo).
- Liviano e interpretable: ideal como feature de entrada al clasificador.
- Alternativa a modelos de sentimiento basados en Transformers, más pesados y opacos.


Las 8 features lingüísticas interpretables

En vez de miles de palabras, describimos cada noticia con 8 rasgos de estilo medibles (spaCy + VADER). Un LR sobre ellos dice qué discrimina, en unidades interpretables.

Feature	Qué mide	Señal esperada
ratio_exclamacion	Signos ! por oración	+ fake (sensacionalismo)
ratio_mayusculas	Palabras en MAYÚSCULAS	+ fake (énfasis/urgencia)
long_oracion_prom	Tokens por oración	+ real (estilo formal)
ratio_adj_sust	Adjetivos / sustantivos	+ fake (lenguaje evaluativo)
sentimiento_vader	Score compuesto VADER	polarización del contenido
densidad_ner	Entidades por oración	+ fake (figuras políticas)
freq_url	Frecuencia del token [URL]	+ fake (origen en redes)
freq_pronombres	Pronombres 1. ^a /2. ^a persona	+ fake (informalidad)

spaCy en_core_web_sm (POS, NER, segmentación) • VADER (sentimiento informal) • Clasificador: Regresión Logística sin scaler → coeficientes interpretables.


Features lingüísticas interpretables (H2)



F2 (val) por campo de texto: título / cuerpo / combinado

H2 refutada

El TÍTULO solo clasifica mejor (F2 val 0,92) que el cuerpo (0,77) y el combinado (0,83). Las señales de estilo se concentran en titulares sensacionalistas.



Coeficientes del LR (8 features) • + = fake, - = real

¿Qué es un embedding?

Un embedding es un vector denso que representa cada palabra según su significado. Palabras con uso similar quedan cerca en el espacio vectorial (*rey - hombre + mujer ≈ reina*). Cada noticia = promedio de los vectores de sus palabras → entrada a un LR / SVM.



GloVe (preentrenado)


- glove.6B.100d: 6.000 millones de tokens, 100 dimensiones.
- Entrenado sobre Wikipedia + Gigaword (texto periodístico).
- Amplia cobertura de vocabulario, pero genérico.
- Elegimos 6B/100d sobre 840B/300d: ganancia marginal, 3× memoria.



Word2Vec (de dominio)

- Entrenado por nosotros sobre ~12,6k docs del train político.
- Captura la jerga específica del corpus 2015-2017.
- Permite comparar embeddings de dominio vs. genéricos.
- Limitación: mezcla efecto de dominio con tamaño del corpus.

Embeddings: GloVe vs. Word2Vec



F2 fake (test) por representación y clasificador

0,945

Word2Vec dominio + LinearSVM (test)

0,905

GloVe genérico + LR (test)

- El Word2Vec de dominio supera al GloVe genérico.
- El vocabulario específico del corpus importa más que el tamaño del preentrenamiento.
- Pero ninguno alcanza el baseline BoW (0,989): la señal es mayormente léxica, no semántica.

Transformers, BERT y fine-tuning

A diferencia del promedio de embeddings, un Transformer usa auto-atención: interpreta cada palabra según TODO su contexto en la oración (“banco” de plaza vs. de dinero).

F Fine-tuning

- Partimos de BERT preentrenado en enormes corpus de texto.
- Ajustamos sus pesos a nuestra tarea (fake vs real) con los datos etiquetados.
- Grilla de hiperparámetros en validación con early stopping sobre F2.
- Aprovecha conocimiento del lenguaje ya aprendido.


D ¿Por qué DistilBERT?

~97%
del rendimiento de BERT-base

60%
de los parámetros

2× más rápido. El fine-tuning de BERT-base es inviable en CPU local; DistilBERT cubre el rol contextual dentro del alcance del TP (extensión opcional en Colab con GPU).

Transformers: DistilBERT



Búsqueda de hiperparámetros en validación (learning rate, batch, warmup)


0,999

F2 fake (test) — el mejor modelo


LECTURA

- DistilBERT logra el F2 más alto de todos los enfoques.
- La ventaja sobre el baseline BoW (0,989) es marginal: el dataset ya era casi separable.
- Costo: GPU y horas de entrenamiento.
- Pierde la interpretabilidad de coeficientes de los modelos lineales.

Importancia de atributos y carga emocional (H1)



Términos con mayor peso lineal por clase (LinearSVM)




Carga emocional (VADER) de adjetivos por clase

H1 sostenida en dirección

Carga emocional de adjetivos fake ($\sim 0,30$) duplica a la de los reales ($\sim 0,12$). La diferencia la marcan pocos adjetivos cargados (great, illegal, criminal).

Comparación de todos los modelos (F2 test)




F2 de la clase fake en test — todos los enfoques

Modelo	F2
DistilBERT	0,999
LinearSVM · BoW(1,2)	0,989
W2V dominio · SVM	0,945
GloVe · LR	0,905
Features ling. (título)	0,904

DistilBERT y el baseline BoW dominan; los enfoques interpretables quedan ~5-8 pts por debajo pero explican QUÉ discrimina.

Análisis de errores: baseline vs. DistilBERT



Distribución de categorías de error por tipo de modelo

- **Baseline: 17 errores totales (6 FP, 11 FN).**
- Categorías más frecuentes: tema político cargado (5), sesgo de fuente (4), información parcialmente verdadera (3).
- **DistilBERT comete muchísimos menos errores (≈2): información parcial y sesgo de fuente.**
- Errores típicos: lenguaje neutral en fake, títulos ambiguos, ironía/sarcasmo.
- Limitación: <30 errores → se analizan todos los disponibles y se documenta.

04

Conclusiones

Qué encontramos, qué limita el trabajo y cómo seguir.

Qué encontramos

H1**Sostenida en dirección**

Adjetivos fake con doble carga emocional que los reales — pero impulsada por pocos términos cargados.

H2**Refutada**

El título solo clasifica mejor que el cuerpo: el estilo sensacionalista vive en los titulares.

H3**No confirmada**

El modelo no depende de marcadores de fuente; aprende patrones lingüísticos (validez del dataset).

MENSAJES CLAVE

- El $F2 \approx 0,99$ NO es evidencia de detección de desinformación: el dataset se separa por artefactos de estilo/fuente.
- El valor real es lingüístico: 8 features interpretables alcanzan $F2 \approx 0,90$ y explican qué rasgos discriminan.
- Transformers (DistilBERT) ganan en métricas, pero pierden interpretabilidad frente a los modelos lineales.

Tan importantes como los resultados

LIMITACIONES

- Fuente única en la clase real: todas las reales son de Reuters → “real” ≈ estilo editorial Reuters, no ley general.
- $F2 \approx 0,99$ como huella de artefacto: el dataset separa casi trivialmente por boilerplate/estructura.
- Reutilización del test en varios experimentos → comparación cross-experimento es exploratoria.
- Split temporal del dataset completo invierte la prevalencia de clases (confound temporal).
- Word2Vec dominio vs. GloVe mezcla efecto de dominio con tamaño del corpus.
- No se entrenó BERT-base ni modelos mayores (costo computacional).

POSIBLES MEJORAS

- Incorporar noticias reales de múltiples fuentes (romper el sesgo Reuters).
- Reportar también balanced-accuracy y AUC-PR para el desbalance.
- Deduplicación difusa (MinHash/LSH) para near-duplicates de boilerplate.
- Evaluar transfer a otros corpus/dominios de noticias.
- Probar modelos contextuales mayores con interpretabilidad (atención, SHAP).

GRACIAS

¿Preguntas?

ANEXO — material de respaldo disponible

- EDA: distribución temporal por clase, puntuación/URLs por clase.
- Exp 1: baselines politics vs. dataset completo (control de sensibilidad).
- Exp 4: bigramas relevantes y nubes de adjetivos por clase.
- Código y notebooks reproducibles (01→07) + informe completo.